

# Foto-trampeo R: Vol.II

Análisis de ocupación y captura-recaptura

*Versión: 2020-04-10 17:11:50*



# Índice general

<b>1. Modelos de ocupación: unmarked</b>	<b>5</b>
<i>Karen Velasquez-Carrillo</i> . . . . .	5
1.1. Introducción . . . . .	5
1.2. Paquete . . . . .	7
1.3. Análisis previo de las covariables . . . . .	7
1.3.1. Estandarización . . . . .	7
1.3.2. Correlación covariables . . . . .	9
1.4. Construcción de los modelos . . . . .	10
1.4.1. Probabilidad de detección . . . . .	12
1.4.2. Promedio de modelos . . . . .	16
1.4.3. Importancia de las covariables . . . . .	17
1.5. Prueba de bondad de ajuste . . . . .	18
1.6. Visualización de resultados . . . . .	20
1.6.1. Probabilidad de detección . . . . .	20
1.6.2. Probabilidad de ocupación . . . . .	21
1.7. Sumario . . . . .	23
1.8. Referencias . . . . .	24



# Capítulo 1

## Modelos de ocupación: unmarked

*Karen Velasquez-Carrillo*

### 1.1. Introducción

Gran parte de la información obtenida en estudios de campo corresponde a datos de presencia o ausencia de un organismo en particular. Dicha información nos indica la ocurrencia de la especie de interés en nuestra área de estudio, y de forma subyacente nos podría dar indicios de la abundancia de la misma (MacKenzie et al. 2006). No obstante la detección de los individuos no es perfecta ni homogénea, lo que en muchos casos nos lleva a pensar que una especie está ausente, simplemente por no ser registrada en un sitio en determinado muestreo. Esto se conoce como una falsa ausencia y puede deberse a diversos factores como el método de muestreo, el comportamiento de la especie o que existan condiciones de hábitat o ambientales que

---

<sup>1</sup>©Mandujano, S. (Ed.). 2020 *Fototrampeo en R: Análisis de ocupación y captura-recaptura. Volumen II. Instituto de Ecología A.C., Xalapa, Ver., México.*

no hayan permitido registrar la especie en determinado sitio y tiempo. Este proceso observacional o logístico es de suma importancia, por que influye directamente sobre el proceso biológico o de interés.

La incorporación del proceso observacional ha sido posible a partir de la implementación de modelos jerárquicos en los que dos modelos están condicionados, es decir la distribución de probabilidad de la variable aleatoria del primer modelos depende de la distribución de probabilidad de la variable aleatoria del segundo modelo (Kéry y Royle 2015), generalmente expresada de la siguiente manera:

$$f(y|z)$$

De este modo, los modelos de ocupación nos permiten a partir de datos de presencia y ausencia, obtener un estimativo de la probabilidad de que un determinado sitio este ocupado o no por nuestra especie de interés, incorporando la probabilidad de que sea detectado o no (MacKenzie et al. 2002). De forma básica los modelos de ocupación se conforman a partir de un modelo de estado (proceso ecológico) y un modelo de observación (detección) que siguen una distribución de probabilidad *Bernoulli*.

$$Z_i \text{ Bernoulli}(\psi)$$

$$y_{ij}|Z_i \text{ Bernoulli}(Z_i p)$$

Los supuestos más importantes dentro de los modelos de ocupación son los siguientes:

- Supuesto de población cerrada, se relaciona directamente con la duración del muestreo, el cual debe ser seleccionado tratando de evitar la entrada o salida de individuos en la población (migración, nacimientos, muertes).
- Falsos positivos, la información recopilada debe ser confiable, y evitar al máximo el registro de falsas detecciones.
- Asegurar la independencia en la detección y la ocurrencia, es decir asegurar la independencia espacial entre un sitio y

otro (ocupación) y temporal entre periodos de muestreo (detección).

- La detección no debe ser heterogénea, la variación en la detección debe ser tenida en cuenta, es decir modelar aquellos factores que podrían influir en la heterogeneidad de la detección.

Los modelos de ocupación son herramientas útiles en análisis de rangos geográficos de distribución, relaciones entre fauna-hábitat y selección de recursos, dinámicas de metapoblaciones, monitoreo a gran escala y análisis de interacción multispecie (MacKenzie et al. 2006).

En este capítulo se pretende ejemplificar el uso de información proveniente de fototrampeo como insumo para el desarrollo de modelos de ocupación con el fin de evaluar el efecto de variables de paisaje y de hábitat en la ocupación (uso de hábitat) y detección de la zorra gris *Urocyon cinereoargenteus*.

## 1.2. Paquete

La paquetería *unmarked* (Fiske y Chandler 2011) permite el desarrollo de modelos jerárquicos de una forma sencilla, como los modelos de ocupación, no obstante permite aplicar una amplia gama de modelos jerárquicos. Para conocer más acerca de la paquetería y sus diversos usos por favor consultar: <https://cran.r-project.org/web/packages/unmarked/unmarked.pdf>

## 1.3. Análisis previo de las covariables

### 1.3.1. Estandarización

Para este ejemplo se incorporarán doce covariables a los modelos de ocupación. Tres variables categóricas o de factor las cuales serán el modelo de cámara trampa utilizado, la orientación del terreno y el

tipo de cobertura predominante; ocho variables de tipo espacial las cuales representan las distancias más cercanas a poblados, a áreas de extracción, a bebederos artificiales y a cultivos, y finalmente dos variables de sitio relacionadas con la estructura de la vegetación en cada punto de muestreo.

```
(cv <- read.csv("Covariables_expl.csv", sep = ",",
               header = FALSE))

##                               V1
## 1                      Distancia a bebederos
## 2                      Distancia a poblados
## 3                      Distancia a cultivos
## 4              Porcentaje cobertura salinas
## 5              Porcentaje cobertura matorral
## 6              Porcentaje cobertura cultivos
## 7 Porcentaje cobertura dominada por Neobuxbamia
## 8              Porcentaje cobertura dominada por Mimosa
## 9              Cobertura total de vegetación
## 10                     Cobertura vertical
## 11                     Modelo de cámara
## 12                     Orientación
```

Ya que las variables provienen de diferentes fuentes y no poseen la misma dimensión, es aconsejable estandarizar las variables numéricas antes de incluirlas en los modelos. De igual forma se debe comprobar que las variables seleccionadas no presenten correlación entre ellas, es decir no estén aportando la misma información.

Para esto, se debe cargar la librería **Vegan** con el fin de realizar la estandarización de las covariables que se incluirán en el modelo.

```
library(vegan)
```

Cargamos la base de datos con la información de las variables, eliminando la columna de sitio o cámara.

```
covar <- read.csv("Covariables.csv", sep="," )
cov.site <- covar[,-1]
```

Extraemos las variables numéricas y se estandarizan mediante la



función `decostand`, incluyendo el objeto con la información de las variables y el método, para este caso `standardize`. A continuación extraemos las covariables categóricas como un factor.

```
cov.num <- cov.site[,sapply(cov.site, is.numeric)]
cov.std <- decostand(cov.num, method = "standardize")
cov.fac <- cov.site[,sapply(cov.site, is.factor)]
```

### 1.3.2. Correlación covariables

Tras tener nuestras variables numéricas estandarizadas, se debe verificar que no exista correlación entre ellas. Para tal fin cargaremos la librería `PerformanceAnalytics`.

```
library("PerformanceAnalytics")
```

Mediante la función `chart.Correlation` visualizamos la relación pareada entre todas nuestras variables numéricas, cargando nuestras variables estandarizadas (`cos.std`) y seleccionando el método de correlación adecuado para la naturaleza de las variables (Figura 1.1).

```
chart.Correlation(cov.std, method = "pearson",
                  histogram = FALSE, pch=23, bg = "blue")
```

En este caso no observamos una correlación fuerte entre las variables ( $r > 0.7$ ), por lo que serán usadas en su totalidad en la formulación de los modelos. Finalmente cargamos en un marco de datos mediante la función `data.frame` todas las variables categóricas y las variables numéricas estandarizadas. En el caso de que se presente una correlación entre las variables, es aconsejable seleccionar solo una de las variables correlacionadas para la construcción de los modelos.

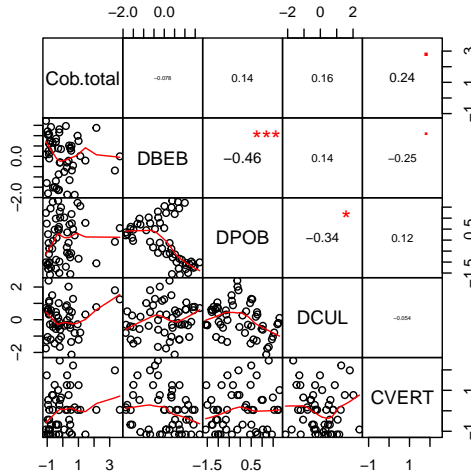


Figura 1.1: Resultado gráfico de la correlación de variables.

```
covs <- data.frame(cov.fac, cov.std)
```

## 1.4. Construcción de los modelos

Para la construcción de los modelos iniciaremos cargando la librería `unmarked`.

```
library(unmarked)
```

Para generar el marco de datos a emplear en los modelos se debe cargar la base de datos correspondiente a las historias de detección de la especie de interés. En este caso se trabajará con registros de la zorra gris *Urocyon cinereoargenteus* obtenidos a partir de información de foto trampeo en la localidad de San Gabriel Casa Blanca, Oaxaca.

Se carga el archivo `.csv` y se elimina la primera columna correspondiente al punto de muestreo. Se crea un objeto el cual contendrá

el marco de datos compuesto por las historias de detección y las covariables, para este caso solo se cargaran covariables de sitio y no de observación.

Es importante corroborar que los datos cargados sean correctos, revisando tanto el `summary` como la estructura `str` del marco de datos.

```
Urci <- read.csv("DetHist_Urci3.csv", sep = ",")
Urcihist <- Urci[,-1]
UmUr <- unmarkedFrameOccu(y = Urcihist,
                           siteCovs = covs, obsCovs = NULL)
summary(UmUr)

## unmarkedFrame Object
##
## 54 sites
## Maximum number of observations per site: 73
## Mean number of observations per site: 28.11
## Sites with at least one detection: 40
##
## Tabulation of y observations:
## 0 1 <NA>
## 1320 198 2424
##
## Site-level covariates:
## CAM Orientacion COVERAGE Cob.total
## Moultrie :11 SO :14 mim :29 Min. :-1.0859
## MoultrieA30:20 NO :13 neo :23 1st Qu.: -0.7775
## Primos :23 Plano :10 scrubs: 2 Median :-0.2351
## SE : 6 Mean : 0.0000
## NE : 4 3rd Qu.: 0.4646
## S : 3 Max. : 3.6484
## (Other): 4
## DBEB DPOB DCUL CVERT
## Min. :-1.8696 Min. :-1.57585 Min. :-2.13312 Min.
## :-1.1581
## 1st Qu.: -0.6888 1st Qu.: -0.95770 1st Qu.: -0.60066 1st
## Qu.: -0.9159
## Median : 0.1805 Median :-0.05745 Median :-0.07604 Median
## : 0.0458
## Mean : 0.0000 Mean : 0.00000 Mean : 0.00000 Mean :
## 0.0000
```

```
## 3rd Qu.: 0.7343 3rd Qu.: 0.76136 3rd Qu.: 0.62852 3rd
Qu.: 0.6197
## Max. : 1.7180 Max. : 1.79225 Max. : 2.39148 Max. :
2.4573
##
```

### 1.4.1. Probabilidad de detección

El primer componente a modelar corresponde al proceso observacional, y se incluirán las variables que puedan influir en el proceso de detección de la especie de interés. En este punto debemos tener cuidado y seleccionar variables informativas para nuestra especie. Un ejemplo de variable que puede afectar la detección es el sexo, pues el comportamiento y los movimientos entre hembras y machos son diferenciales, incidiendo en que la probabilidad de detección no sea homogénea entre sexos.

En el ejemplo incorporaremos el tipo de cámara como variable categórica que podría afectar la detección, la cobertura vertical y la cobertura total de la vegetación, teniendo en cuenta que en áreas muy densas la detección puede ser menor. Iniciaremos con el modelo nulo, generando un objeto en el cual se guardaran los resultados `fmUr1`, se empleara la función `occu` y se incluirá el marco de datos creado anteriormente (`UmUr`).

```
summary(fmUr1 <- occu(~1 ~1, data = UmUr))
```

```
##
## Call:
## occu(formula = ~1 ~ 1, data = UmUr)
##
## Occupancy (logit-scale):
## Estimate SE z P(>|z|)
## 15.7 NaN NaN NaN
##
## Detection (logit-scale):
## Estimate SE z P(>|z|)
## -1.9 0.0762 -24.9 8.91e-137
##
## AIC: 1179.576
```

```
## Number of sites: 54
## optim convergence code: 0
## optim iterations: 13
## Bootstrap iterations: 0
```

El modelo nulo representa la interpretación más sencilla tanto del proceso ecológico como observacional, en la que estos no están siendo afectados por ningún factor externo.

No obstante, los modelos de ocupación nos permiten ir mas allá de conocer la ocurrencia o no de una especie en un sitio determinado, nos permiten relacionar los factores bióticos que estarían aportando a que nuestra especie de interés se encuentre en dicho sitio e incluso nos permite predecir la probabilidad de ocupación en otras áreas de interés. Se pueden especificar otros modelos como:

```
summary(fmUr2 <- occu(~CAM ~1, data = UmUr))
summary(fmUr3 <- occu(~CVERT ~1, data = UmUr))
summary(fmUr4 <- occu(~Cob.total ~1, data = UmUr))
```

Al finalizar la computación de los modelos los organizaremos mediante la función `fitList`, permitiéndonos así evaluar el mejor modelo usando la función `modSel`. Seleccionaremos el mejor modelo que represente la probabilidad de detección mediante el criterio de información de Akaike (AIC), seleccionando así el modelo con menor valor de AIC.

```
fms <- fitList ("p(.)psi(.)"      = fmUr1,
               "p(CAM)psi(.)"    = fmUr2,
               "p(CVERT)psi(.)"  = fmUr3,
               "p(Cob.total)psi(.)" = fmUr4)
(ms <- modSel(fms))
```

##		nPars	AIC	delta	AICwt	cumltvWt
##	p(CAM)psi(.)	4	1110.28	0.00	1.0e+00	1.00
##	p(Cob.total)psi(.)	3	1125.88	15.60	4.1e-04	1.00
##	p(CVERT)psi(.)	3	1126.33	16.05	3.3e-04	1.00
##	p(.)psi(.)	2	1179.58	69.29	9.0e-16	1.00

En este caso, el mejor modelo corresponde a aquel que incluye el modelo de la cámara como variable que tiene mayor influencia en la probabilidad de detección. A partir de nuestro mejor modelo para

el proceso observacional construiremos los modelos para el proceso ecológico. Mantendremos la variable CAM para el proceso observacional e incorporemos las variables que designamos como importantes en la probabilidad de ocupación. Otros modelos pueden ser:

```
summary(fmUr5 <- occu(~CAM ~DBEB, data = UmUr))
summary(fmUr6 <- occu(~CAM ~DCUL, data = UmUr))
summary(fmUr7 <- occu(~CAM ~DPOB, data = UmUr))
summary(fmUr8 <- occu(~CAM ~Cob.total, data = UmUr))
summary(fmUr9 <- occu(~CAM ~CVERT, data = UmUr))
summary(fmUr10 <- occu(~CAM ~COVERAGE, data = UmUr))
summary(fmUr11 <- occu(~CAM ~Orientacion, data = UmUr))
summary(fmUr12 <- occu(~CAM ~DCUL + DPOB, data = UmUr))
summary(fmUr13 <- occu(~CAM ~CVERT + Cob.total,
                        data = UmUr))
```

Al igual que en los modelos construidos para la detección, organizamos en una lista los modelos y con la función `modSel` obtenemos los datos organizados de los modelos según el valor de AIC.

```
fms <- fitList ("p(CAM)psi(DBEB)"           = fmUr5,
               "p(CAM)psi(DCUL)"           = fmUr6,
               "p(CAM)psi(DPOB)"           = fmUr7,
               "p(CAM)psi(Cob.total)"       = fmUr8,
               "p(CAM)psi(CVERT)"          = fmUr9,
               "p(CAM)psi(COVERAGE)"       = fmUr10,
               "p(CAM)psi(Orientacion)"    = fmUr11,
               "p(CAM)psi(DCUL+DPOB)"      = fmUr12,
               "p(CAM)psi(CVERT+Cob.total)" = fmUr13
               )
(ms <- modSel(fms))
```

```
## nPars AIC delta AICwt cumltvWt
## p(CAM)psi(DCUL) 5 1107.57 0.00 0.415 0.42
## p(CAM)psi(DCUL+DPOB) 6 1108.69 1.12 0.237 0.65
## p(CAM)psi(Cob.total) 5 1109.72 2.15 0.141 0.79
## p(CAM)psi(CVERT+Cob.total) 6 1111.66 4.09 0.054 0.85
## p(CAM)psi(CVERT) 5 1111.90 4.34 0.047 0.90
## p(CAM)psi(DBEB) 5 1112.23 4.67 0.040 0.94
## p(CAM)psi(DPOB) 5 1112.27 4.70 0.040 0.97
## p(CAM)psi(COVERAGE) 6 1113.72 6.16 0.019 0.99
```

```
## p(CAM)psi(Orientacion) 11 1116.03 8.46 0.006 1.00
```

En este caso, los mejores modelos presentaron las variables de distancia a cultivos y distancia a centros poblados. Todos los modelos presentan valores de AIC muy cercanos, por lo que es necesario promediar dichos modelos.

Con el fin de obtener el valor de probabilidad de detección y ocupación real de la especie, realizamos una transformación de los valores estimados obtenidos mediante la función `backTransform`:

```
backTransform(linearComb(fmUr7, coefficients = c(1,0),
                                type = "state"))
```

```
## Backtransformed linear combination(s) of Occupancy
estimate(s)
```

```
##
```

```
## Estimate SE LinComb (Intercept) DPOB
```

```
## 0.816 0.065 1.49 1 0
```

```
##
```

```
## Transformation: logistic
```

```
backTransform(linearComb(fmUr7, coefficients = c(1,0,0),
                                type = "det"))
```

```
## Backtransformed linear combination(s) of Detection
estimate(s)
```

```
##
```

```
## Estimate SE LinComb (Intercept) CAMMoultrieA30 CAMPrimos
```

```
## 0.0714 0.0249 -2.56 1 0 0
```

```
##
```

```
## Transformation: logistic
```

```
backTransform(linearComb(fmUr5, coefficients = c(1,0),
                                type = "state"))
```

```
## Backtransformed linear combination(s) of Occupancy
estimate(s)
```

```
##
```

```
## Estimate SE LinComb (Intercept) DBEB
```

```
## 0.82 0.068 1.52 1 0
```

```
##
```

```
## Transformation: logistic
```

```
backTransform(linearComb(fmUr5, coefficients = c(1,0,0),
                        type = "det"))

## Backtransformed linear combination(s) of Detection
estimate(s)
##
## Estimate SE LinComb (Intercept) CAMMoultrieA30 CAMPrimos
## 0.07 0.0255 -2.59 1 0 0
##
## Transformation: logistic
```

### 1.4.2. Promedio de modelos

En el caso de obtener modelos con valores de AIC muy cercanos ( $\Delta \text{AIC} < 2$ ), es necesario promediarlos con el fin de tener estimaciones promedio de nuestros parámetros de interés. Para tal fin, cargaremos la librería `MuMin`, generamos un objeto en el que listaremos los modelos a promediar `BestUr` y mediante la función `model.avg` realizamos el promedio del objeto que contiene la lista.

Obtenemos una tabla de resultados que describe los componentes de los modelos, los coeficientes de los modelos promediados y el valor de importancia relativa.

```
library(MuMin)
BestUr <- list(fmUr6, fmUr12)
avgmodUr <- model.avg(BestUr, fit = TRUE)
summary(avgmodUr)

##
## Call:
## model.avg(object = BestUr, fit = TRUE)
##
## Component model call:
## occu(formula = <2 unique values>, data = UmUr)
##
## Component models:
## df logLik AICc delta weight
## 12 5 -548.78 1108.82 0.00 0.7
## 123 6 -548.34 1110.47 1.66 0.3
```



```
##
## Term codes:
## p(CAM) psi(DCUL) psi(DPOB)
## 1 2 3
##
## Model-averaged coefficients:
## (full average)
## Estimate Std. Error z value Pr(>|z|)
## psi(Int) 1.7683 0.5855 3.020 0.00253 **
## psi(DCUL) -0.9389 0.4927 1.906 0.05670 .
## p(Int) -2.5835 0.3857 6.699 < 2e-16 ***
## p(CAMMoultrieA30) 1.2696 0.3999 3.175 0.00150 **
## p(CAMPrimos) 0.7821 0.4027 1.942 0.05210 .
## psi(DPOB) -0.1582 0.4049 0.391 0.69593
##
## (conditional average)
## Estimate Std. Error z value Pr(>|z|)
## psi(Int) 1.7683 0.5855 3.020 0.00253 **
## psi(DCUL) -0.9389 0.4927 1.906 0.05670 .
## p(Int) -2.5835 0.3857 6.699 < 2e-16 ***
## p(CAMMoultrieA30) 1.2696 0.3999 3.175 0.00150 **
## p(CAMPrimos) 0.7821 0.4027 1.942 0.05210 .
## psi(DPOB) -0.5203 0.5921 0.879 0.37959
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1
' ' 1
```

Tras realizar el promediado de los modelos fmUr6 y fmUr12 se observa que ninguna de las variables incluidas para explicar la ocupación de la especie es significativa.

### 1.4.3. Importancia de las covariables

Otra alternativa para analizar la importancia de las covariables, es analizar sus intervalos de confianza en cada uno de los mejores modelos. Cuando los intervalos de confianza de una variable solapan el cero, quiere decir que su efecto sobre el parámetro de interés no es importante, ya que puede ser tanto negativo como positivo.

- Intervalos de confianza modelo fmUr6

```
confint(fmUr6, type = "state")
```

```
##              0.025      0.975
## psi(Int)    0.6540304 2.786165906
## psi(DCUL) -1.7555392 0.009809521
```

```
confint(fmUr6, type = "det")
```

```
##              0.025      0.975
## p(Int)      -3.3275044 -1.819637
## p(CAMMoultrieA30) 0.4781775 2.042137
## p(CAMPrimos) -0.0141979 1.562992
```

- Intervalos de confianza modelo fmUr12

```
confint(fmUr12, type = "state")
```

```
##              0.025      0.975
## psi(Int)    0.5890534 3.16794810
## psi(DCUL) -2.1656334 -0.01406392
## psi(DPOB) -1.6807987 0.64026942
```

```
confint(fmUr12, type = "det")
```

```
##              0.025      0.975
## p(Int)      -3.36450002 -1.847617
## p(CAMMoultrieA30) 0.50501388 2.077145
## p(CAMPrimos) 0.01016187 1.589073
```

## 1.5. Prueba de bondad de ajuste

En algunos casos el o los mejores modelos no siempre son un “buen” modelo, esto quiere decir que no nos ayuda a explicar lo que realmente esta pasando. Para saber si un modelo es bueno, el siguiente paso es aplicar una prueba de bondad de ajuste. En este caso aplicaremos la prueba desarrollada por (MacKenzie y Bailey 2004) para saber si nuestro modelo se ajusta de manera adecuada. Para la realización de la prueba es necesario cargar la librería `AICcmodavg`, y se emplea la función `mb.gof.test` como se ejemplifica a continuación:

```
library(AICcmodavg)
```

```
mb_Urci12 <- mb.gof.test(fmUr12, nsim = 200,
                          plot.hist = TRUE)
```

Resultado modelo fmUm12

```
Chi-square statistic = 5.943237e+17
Number of bootstrap samples = 200
P-value = 0
```

```
Quantiles of bootstrapped statistics:
      0%      25%      50%      75%     100%
8.9e+08 7.1e+09 2.2e+10 7.3e+10 6.7e+12
```

```
Estimate of c-hat = 4079294
```

```
mb_Urci6 <- mb.gof.test(fmUr6, nsim = 200,
                         plot.hist = TRUE)
```

Resultado fmUr6

```
Chi-square statistic = 5.453726e+17
Number of bootstrap samples = 200
P-value = 0
```

```
Quantiles of bootstrapped statistics:
      0%      25%      50%      75%     100%
1.2e+09 1.3e+10 3.8e+10 1.5e+11 1.3e+13
```

```
Estimate of c-hat = 1402651
```

Como resultado de la prueba tenemos dos parámetros informativos:

1. El resultado de la prueba  $\chi^2$  de nuestro estimador y el re muestreo. Si la prueba presenta un p-valor  $< 0.05$  quiere decir que el modelo no se ajusta de manera adecuada.
2. El valor de **c-hat**. Es un parámetro que nos informa sobre la dispersión del modelo, cuando un modelo esta bien ajustado el **c-hat** es igual a 1, en caso de tener sobre dispersión el valor será  $> 1$  y subdispersión cuando sea  $< 1$ .

En nuestro caso, ninguno de los modelos se ajusta de manera ade-

cuada, y ambos presentan un alto nivel de sobredispersión. Esto puede deberse a diferentes factores; ya sea que las covariables que medimos no sean las adecuadas o que nuestra cantidad de registros sea baja en comparación con los ceros.

## 1.6. Visualización de resultados

### 1.6.1. Probabilidad de detección

La mejor alternativa para la visualización de las predicciones tanto de la probabilidad de detección como de ocupación es mediante gráficos, ya que nos permite ver como se comporta la detección y la ocupación a partir de las variables incorporadas. Para la realización de los gráficos cargaremos la paquetería `ggplot2`:

```
library(ggplot2)
```

La generación de los gráficos de predicción se obtienen a partir del siguiente código:

```
newData <- data.frame(CAM = c("Moultrie", "MoultrieA30",  
                             "Primos"))  
statepredict <- predict(fmUr6, type = 'det',  
                       newdata = newData, appendData = TRUE)  
CAMplot <- ggplot(statepredict, aes(x = CAM,  
                                   y = Predicted)) + ylim(0,1) +  
  labs(x = "Modelo de cámara",  
       y = "Probabilidad de detección") +  
  geom_point(data = statepredict) +  
  geom_errorbar(data = statepredict,  
               aes(ymin = lower, ymax = 0.50),  
               alpha = 0.8, width = 0.25, colour = "black") +  
  theme_classic()  
CAMplot
```

En el caso de la detección podemos observar que en la (Figura 1.2) que la marca y modelos de las cámaras influye sobre la detección de




Figura 1.2: Relación entre la probabilidad de detección y el modelo de la cámara.

la especie, en particular el modelo de Moultrie A30 parece tener un mejor desempeño.

### 1.6.2. Probabilidad de ocupación

Por otra parte la probabilidad de ocupación de la especie se vio afectada por las variables de paisaje distancia a poblados (DPOB) (Figura 1.3), distancia a cultivos (DCUL) con el modelo **fmUr6** (Figura 1.4) y con el modelo **fmUr12** (Figura 1.5). Particularmente la distancia a cultivos es una variable importante, debido a que los modelos que la contienen presentan los menores valores de AIC y sus intervalos de confianza no solapan (**fmUr12**) o solapan de forma parcial (**fmUr6**) el cero. Como se observa en las gráfica, las variables distancia a cultivos y distancia a poblados afectan de forma negativa la ocupación de la especie.

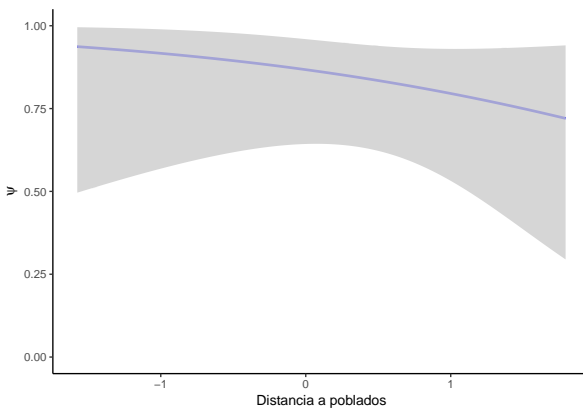


Figura 1.3: Relación entre la probabilidad de ocupación y la distancia a poblados.




Figura 1.4: Relación entre a probabilidad de ocupación y la distancia a cultivos para el modelo fmUr6.

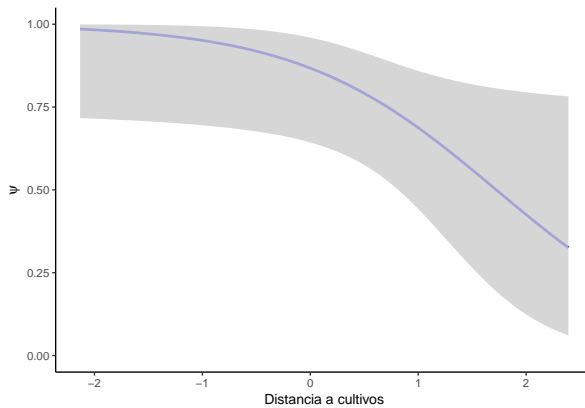


Figura 1.5: Relación entre la probabilidad de ocupación y la distancia a cultivos en el modelo fmUr12.

## 1.7. Sumario

Los modelos de ocupación son un tipo de modelo jerárquico que nos permiten evaluar la probabilidad de que un determinado sitio se encuentre o no ocupado por una especie a partir de información de detección o no detección. El parámetro ( $\psi$ ) definido como la probabilidad de ocupación, depende directamente de la probabilidad de detección de la especie en el sitio de estudio, y la detección se relaciona con el número de sitios evaluados y la cantidad de réplicas temporales. Estos modelos son útiles en el análisis de rangos de distribución de especies, relación de variables de hábitat con presencia de especies y programas de monitoreo a gran escala. Pueden ser construidos en softwares como PRESENCE, no obstante de forma más reciente la implementación de paqueterías de análisis en R como *unmarked* (Fiske y Chandler 2011) permiten la construcción de modelos de ocupación en los que se facilita la incorporación de covariables y el desarrollo de diversos modelos jerárquicos, como modelos para estimación de abundancia Royle-Nichols y N-mixtos (Kéry y Royle 2015). Los modelos de ocupación son muy útiles principalmente con aquellas especies que presentan hábitos crípticos, que no

pueden ser individualizadas y de las que se obtiene generalmente poca información.

## 1.8. Referencias

- Fiske, I., and R. Chandler. 2011. “Unmarked: An R Package for Fitting Hierarchical Models of Wildlife Occurrence and Abundance.” *Journal of Statistical Software* 43 (10): 1–23.
- Kéry, M., and J. A. Royle. 2015. *Applied Hierarchical Modeling in Ecology: Analysis of Distribution, Abundance and Species Richness in R and Bugs: Volume 1: Prelude and Static Models*. Academic Press.
- MacKenzie, D. I., and L. L. Bailey. 2004. “Assessing the Fit of Site-Occupancy Models.” *Journal of Agricultural, Biological, and Environmental Statistics* 9 (3). Springer: 300–318.
- MacKenzie, D. I., J. D. Nichols, G. B. Lachman, S. Droege, A. J. Royle, and C. A. Langtimm. 2002. “Estimating Site Occupancy Rates When Detection Probabilities Are Less Than One.” *Ecology* 83 (8). Wiley Online Library: 2248–55.
- MacKenzie, D.I., J.D. Nichols, J.A. Royle, K.H. Pollock, L.L. Bailey, and J.E. Hines. 2006. *Occupancy Estimation and Modelling*. Academic Press, Burlington, Massachusetts.